

Zpracování obsahů z naskenovaných dokumentů

PROJEKT DO PŘEDMĚTU KNN

Jakub Vlk (xvlkja07)

Veronika Nevařilová (xnevar00)

Emma Krompaščíková (xkromp00)

ÚVOD A CÍL


Manuální zpracování rozsáhlých naskenovaných obsahů knih je neefektivní. Cílem projektu bylo navrhnout a porovnat systémy pro automatickou extrakci strukturovaných informací o kapitolách (název, číslo kapitoly, číslo strany, hierarchie podkapitol) z obrázků obsahů do formátu JSON.

BASELINE A ZKOUMANÝ PŘÍSTUP 1: END-TO-END MODEL DONUT

- Využívá model **DONUT** (Document Understanding Transformer), end-to-end řešení založené na architektuře Transformer.
- Nevyžaduje OCR modul.
- Model je trénován přímo na transformaci vstupního obrázku na požadovaný JSON výstup.
- Pro trénink byl použit model předtrénovaný na úloze zpracování účtenek (CORD dataset).




Obr. 1: Schéma zpracování end-to-end modelu DONUT




Obr. 2: Příklad vstupního obrázku a přímého JSON výstupu z modelu DONUT

ZKOUMANÝ PŘÍSTUP 2: PERO OCR + LAYOUTLMV3

- Využívá nástroj **PERO OCR** pro rozpoznání textu a získání jeho souřadnic (bounding boxů) z obrázku ve formátu ALTO.
- Data z PERO OCR jsou předzpracována pro model **LayoutLMv3**, který klasifikuje každý textový token (např. jako název kapitoly, číslo strany).
- Finální JSON soubor s extrahovaným obsahem je generován z klasifikovaných tokenů a jejich pozic pomocí sady pravidel a heuristik.



Obr. 3: Schéma zpracování pipeline PERO OCR + LayoutLMv3



Obr. 4: Příklad vizualizace klasifikovaných tokenů a výsledného JSON pro PERO OCR + LayoutLMv3

DATASETY

- Pro DONUT:** ~5300 párů (obrázek, JSON). Cílové JSON struktury byly vygenerovány LLM (Gemini 2.0 Flash), následně validovány.
- Pro PERO OCR + LayoutLMv3:** ~1000 vzorků (obrázek, anotovaná slova). Anotace vycházely z výstupů PERO OCR a manuálně poskytnutých anotací oblastí textu.
- Oba datasety zahrnovaly dokumenty v 7 jazycích: čeština, staročeština, němčina, latina, angličtina, italština a slovenština.

EXPERIMENTY A VÝSLEDKY

- Experimenty s různými přístupy k výrobě výsledného jsonu.
- Modely byly trénovány a evaluovány pomocí metrik:
 - Normalizovaná Tree Edit Distance**
 - Měří strukturální podobnost (vyšší je lepší).
 - F1 skóre**
 - Měří přesnost a úplnost extrakce (vyšší je lepší).
- Model DONUT prokázal lepší schopnost zachytit strukturu a přesněji extrahovat jednotlivé položky obsahu.

Metoda	Max. zanoření	Norm. TED	F1 skóre
DONUT	6	0.70	0.39
DONUT	2	0.75	0.42
LayoutLMv3	2	0.73	0.19

Tab. 1: Srovnání výkonnosti metod s ohledem na počet zanoření

ZÁVĚR A KLÍČOVÁ ZJIŠTĚNÍ

- End-to-end model **DONUT** dosáhl **superiorních výsledků** pro úlohu extrakce strukturovaných obsahů.
- Hlavní limitací přístupu PERO OCR + LayoutLMv3 byla **komplexnost a nižší přesnost finálního kroku** – konverze klasifikovaných slov na strukturovaný JSON pomocí pravidel; nízké F1 skóre (0.19) poukazuje na problémy v přesnosti a úplnosti.
- Přestože DONUT nebyl původně trénován na českém jazyce, dokázal se **úspěšně adaptovat** a správně rozpoznávat české znaky a texty po několika epochách tréninku.
- Generování tréninkových dat pomocí LLM pro DONUT se ukázalo jako **efektivní metoda**, ačkoliv vyžaduje následnou validaci.